

双向流式语音合成 WebSocket

豆包语音

法律声明

本《豆包语音》的所有内容，包括但不限于文字、商标、架构、图示、图片、页面布局等，其知识产权（著作权、商标权、专利权、商业秘密等）归属于北京火山引擎科技有限公司及其关联公司（火山引擎），非经火山引擎书面同意，任何个人和组织不得复制、使用、修改、转发或以任何违反本《豆包语音》所承载的目的进行传播。

本《豆包语音》陈述内容仅作为产品的通用性介绍和参考性指引，火山引擎保留按“现状”和“当前可用”的形式提供产品和服务的权利。火山引擎不对本《豆包语音》中所载的产品功能、性质、质量、标准等内容进行明示或默示的保证和承诺，最终以您与火山引擎实际签署的协议为准。

如您发现本《豆包语音》有任何错误或歧义，或发现有对本《豆包语音》、产品本身的侵权行为，请与火山引擎取得联系。

联系方式：service@volcengine.com，400-850-0030
(周一至周五 10:00-18:00)

目录

法律声明-----1

目录-----1

1. 双向流式语音合成WebSocket-----1

1. 双向流式语音合成WebSocket

基于 WebSocket 的双向流式 TTS 接口，支持文本流式输入、音频流式输出，低时延，适用于实时交互场景，覆盖多语种与多方言。

运行依赖文件

【附件下载】：[TTS Websocket Bidirection protocols.zip](#)，大小为

WSS <wss://openspeech.bytedance.com/api/v3/tts/bidirection>

请求头

****X-API-Key **** `string` `%%require%%`

API Key 可从 [控制台>API Key管理](#) 获取

说明

同时支持[旧版控制台](#)的鉴权方式，详见[旧版控制台鉴权参考](#)

****X-API-Resource-Id **** `string` `%%require%%`

请求的模型版本，可选值：

- `seed-tts-2.0` :豆包语音合成大模型2.0，支持使用[豆包语音合成模型2.0音色](#)
- `seed-icl-2.0` :豆包声音复刻大模型2.0，支持使用声音复刻接口克隆的音色，具体音色详见[控制台>音色库](#)

X-API-Connect-Id `string`

用于追踪当前连接情况的标志 ID

****X-Control-Require-Usage-Tokens-Return **** `string`

若设置为 `*`，会返回计费的字符数

事件

建立连接

****EventType **** `string`

请求事件类型。建立连接时，字段固定为 `StartConnection`

创建会话

****EventType **** `string`

请求事件类型。创建会话时，字段固定为 `StartSession`

****session_id **** `string`

合成会话id，由客户端生成

****req_params**** `object` `%%require%%`

model `string`

指定模型版本，默认值为 `seed-tts-2.0-standard`

说明

仅当 `speaker` 参数为复刻音色时需指定此参数，且指定后不支持使用语音指令 `context_texts`

text `string`

输入待合成的文本

speaker `string` `%%require%%`

指定音色 ID，具体的音色ID可从[控制台 > 音色库](#) [🔗](#)获取

audio_params `object` `%%require%%`

音频参数

format `string`

指定音频格式，默认值为 `mp3`，支持 `mp3` / `pcm` / `ogg_opus` / `wav`

说明

流式场景推荐使用 `pcm`，不建议使用 `wav`

sample_rate `int`

指定输出音频的采样率，单位为Hz，不同音频格式支持的比特率不同，具体如下：

- `wav` / `pcm` / `mp3` 默认值为 `24000`，取值范围为[`8000` , `16000` , `22050` , `24000` , `32000` , `44100` , `48000`]
- `ogg_opus` 仅支持 `48000`

bit_rate `int`

指定音频比特率，单位 bps，不同音频格式对比特率支持的情况不同，具体如下：

- `mp3`：默认为 `64000`，可选值[`64000` , `160000`]
- `ogg_opus`：可选值[`64000` , `160000`]
- `wav` / `pcm`：不支持指定比特率

说明

当设置 `disable_default_bit_rate` 为 `true` 后，可选值[`16000` , `32000` , `64000` , `160000`]

speech_rate `int`

指定音频的语速，取值范围 [`-50` , `100`]。其中，取值 `100` 代表2.0倍速，`-50` 代表0.5倍速

loudness_rate `int`

指定音频的音量，取值范围 [`-50` , `100`]。其中，取值 `100` 代表2.0倍音量，`-50` 代表0.5倍音量

enable_subtitle `bool`

启用字幕服务，开启后将返回字级别的时间戳，默认值为 `false`

说明

仅支持中文和英文语种

additions `string`

`**max_length_to_filter_parenthesis` `int`

指定过滤括号内文本的长度，单位为字符，默认为0（即不过滤），推荐取值范围0~100

说明

- 该参数用于过滤文本中括号内的注释、补充说明等无需朗读的内容
- 当括号内文本字符数超过设定值时，该括号的过滤功能将失效，括号内内容会被正常朗读。若存在较长的括号文本需要过滤，建议客户端在送入合成前自行完成前置过滤，以避免过滤失效及不必要的时延

disable_markdown_filter `bool`

Markdown解析过滤参数，默认值为 `false`

- `true`：启用后，系统会解析并去除Markdown语法，例如 `**你好**` 朗读为 "你好"
- `false`：停用后，系统会保留原始字符，例如 `**你好**` 朗读为 "星星你好星星"

disable_emoji_filter `bool`

Emoji解析过滤参数，默认值为 `false`

- `true`：启用后，系统会解析并去除文本中的Emoji符号
- `false`：停用后，系统会保留文本中的Emoji符号

latex_parser `string`

启用Latex文本朗读能力功能。可取值：`v2`

说明

- 该参数适用于教育场景，启用后，会增加一定的时延。
- 启用该参数时，需同时将 `disable_markdown_filter` 设置为 `true`

explicit_language `string`

指定朗读语种。开启后，仅朗读指定语种的文本，其他语种的内容会被跳过或合成失败，支持的语种如下：

- `zh-cn`：中文为主，支持中英混读
- `en`：仅朗读英语
- `ja`：仅朗读日语
- `es-mx`：仅朗读墨西哥语
- `id`：仅朗读印度尼西亚语
- `pt-br`：仅朗读巴西葡萄牙语
- `pt`：仅朗读葡萄牙语
- `ko`：仅朗读韩语

- `it` : 仅朗读意大利语
- `de` : 仅朗读德语
- `fr` : 仅朗读法语
- `th` : 仅朗读泰语
- `vi` : 仅朗读越南语
- `ru` : 仅朗读俄语
- `fil` : 仅朗读菲律宾语
- `ms` : 仅朗读马来语
- `ar` : 仅朗读阿拉伯语
- `pl` : 仅朗读波兰语
- `tr` : 仅朗读土耳其语
- `sv` : 仅朗读瑞典语

注意

启用该参数后，输入文本须包含指定语种的内容，否则请求将无法返回

explicit_dialect `string`

指定方言。

- `beijing` : 北京话
- `dongbei` : 东北话
- `henan` : 河南话
- `shaanxi` : 陕西话
- `shanghai` : 上海话
- `sichuan` : 四川话
- `tianjin` : 天津话
- `yue` : 粤语

说明

使用该参数时，`speaker` 需设置支持方言的音色，音色的详细情况请参见：[音色列表](#)

aigc_watermark `bool`

启用AIGC生成标识，默认值：`false`。开启后，将在音频合成结尾添加节奏标识。

aigc_metadata `object`

在合成音频中添加meta水印，支持音频格式 `mp3` / `wav` / `ogg_opus`

****enable**** `bool`

启用meta隐式水印，默认值：`false`

content_producer `string`

指定合成服务提供者的名称或编码

****produce_id**** `string`

指定内容制作编号

content_propagator `string`

指定内容传播服务提供者的名称或编码

****propagate_id**** `string`

指定内容传播编号

post_process `object`

后处理相关配置

****pitch**** `int`

指定音调，默认值为0，默认不调整音调，取值范围：[-12,12]

取值越大，音调越高（声音越尖锐、越明亮）；取值越小，音调越低（声音越低沉，越厚重）

context_texts `array`

配置语音指令

示例：

Python

```
"context_texts":["你可以用特别特别痛心的语气说话吗?"]
```

说明

- 仅 `speaker` 参数设置为[豆包语音合成模型2.0音色](#)时，支持使用语音指令
- 该字段文字不参与计费

section_id `string`

多轮会话 ID 用于关联同一上下文中的多次串行语音合成请求。服务端通过该 ID 在一次语音合成结束后保存对话历史，并在后续语音合成请求中，使用相同的 ID 读取对应的历史记录。

取值示例：如在一通电话中的多次 TTS 请求，建议为该通电话使用 UUID 生成一个唯一的 `section_id`，并在所有 TTS 请求中传递相同的 `section_id`。

示例：`section_id="bf5b5771-31cd-4f7a-b30c-f4ddcbf2f9da"`

说明

- 该参数仅支持[豆包语音合成模型2.0音色](#)、豆包声音复刻大模型2.0音色
- 服务端对历史上下文有相应的轮数限制和超时时间。

pronunciation_dict `object`

配置发音词典，修正指定文本的发音

tone `object`

配置发音规则数组，支持发音修正与文本转写两类规则

- 发音修正：`原词/(拼音音节)`，用于指定词汇的具体发音
- 文本转写：`原词/目标文本`，用于将原词替换为目标文本后再合成

示例：

Python

```
"req_params": {
    "text": "我在北京用 mobile 说 omg",
    "speaker": "zh_female_vv_uranus_big tts",
    "audio_params": {
        "format": "mp3",
        "sample_rate": 24000
    },
    "additions": "{\"pronunciation_dict\":{\"tone\":[\"北京/(bei3)(jing1)\",\"omg/oh my god\"]}}"
```

说明

- `tone` 中每条规则采用 `原词/修正内容` 格式，以 `/` 分隔。服务端按文本从左到右进行贪心最长匹配，存在多个可匹配词条时，优先匹配更长的原词
- 最多支持配置 5000 个词条；每个原词长度不超过 9 个字符，不能为空、不能包含空格、不可重复
- 仅豆包语音合成大模型2.0、豆包语音复刻大模型2.0对应的中英文音色支持
- 命中发音字典规则的文本片段不支持 SSML 标签，同时使用时 SSML 标签将失效，建议二者择一

发送请求

****EventType**** `string`

请求事件类型。发送请求时，字段固定为 `TaskRequest`

****session_id**** `string`

合成会话ID

****text**** `string` `%%require%%`

待合成的输入文本

取消会话

****EventType**** `string`

请求事件类型。取消会话时，字段固定为 `CancelSession`

结束会话

****EventType**** `string`

请求事件类型。结束会话时，字段固定为 `FinishSession`

结束连接

****EventType**** `string`

请求事件类型。结束连接时，字段固定为 `FinishConnection`

响应

EventType string

响应事件类型。包含以下几种事件：

- **ConnectionStarted** : 建连成功
- **SessionStarted** : 会话开始
- **TTSSentenceStart** : 开始合成音频
- **TTSResponse** : 音频合成内容
- **TTSSentenceEnd** : 音频合成结束
- **TTSSubtitle** : 返回音频合成字幕
- **SessionFinished** : 会话结束
- **ConnectionFinished** : 连接结束
- **SessionCanceled** : 会话取消
- **ConnectionFailed** : 建连失败
- **SessionFailed** : 会话失败

****MsgType **** string

消息类型。响应消息类型有以下两种

- **FullServerResponse**
- **AudioOnlyServer**

****Sessiold **** string

会话 ID，用于标识一次合成会话

****PayloadSize **** int

返回的音频片段大小，单位是字节

****ConnectId **** string

连接 ID，用于标识当前 WebSocket 连接

****Payload **** object

当前事件携带的响应内容

****phonemes **** object

音素相关时间戳

****text **** string

合成音频文本

****words **** object

字级别时间戳

****confidence **** float

时间戳置信度，范围 0~1

****startTime **** float

开始时间（秒）

****endTime **** float

结束时间（秒）

****word **** string

字

****usage **** object

本次请求的资源消耗统计

****text_words **** int

本次请求计费的文本字数（含标点）